



Aprendizagem de Máquina Supervisionada

Uma introdução teórica

Nesta aula, exploraremos como os computadores podem aprender padrões a partir de dados rotulados(etiquetados), transformando a forma como resolvemos problemas complexos através da Inteligência Artificial.

Fundamentos de Machine Learning



Aprendizagem de Máquina Supervisionada

Objetivos

Objetivo: fazer o computador **aprender padrões a partir de dados**

Em vez de programar regras explícitas, o algoritmo “descobre” as regras sozinho

Analogia: Ensinar uma criança a reconhecer gatos: você mostra muitos exemplos (fotos) e ela aprende as características comuns.

Fundamentos de Machine Learning

Por que a Aprendizagem de Máquina é Necessária?

Superando as limitações da programação tradicional

Fragilidade de Regras Manuais

Definir regras como "gato tem bigodes" falha porque tigres também têm. Regras manuais são inerentemente incompletas e difíceis de manter em cenários complexos.

Complexidade dos Dados

Dados do mundo real são vastos, ruidosos e mudam constantemente. Programar cada variação manualmente é impossível.

Escalabilidade e Velocidade

Máquinas conseguem processar e aprender com milhares de exemplos em segundos, identificando padrões sutis que escapam à percepção humana.

Mudança de Paradigma

Em vez de **Entrada + Regras = Saída**, passamos para **Entrada + Saída = Regras**. O algoritmo descobre a lógica por trás dos dados.

O Conceito de Aprendizado Supervisionado

Mapeando entradas para saídas desejadas

Features (Entradas)

As características ou variáveis que descrevem o problema (ex: tamanho da casa, número de quartos).

Rótulos (Saídas)

A resposta correta ou o valor que queremos prever (ex: o preço final da casa).

O algoritmo aprende a função que mapeia **Entrada** → **Saída** para prever resultados em novos dados nunca vistos.



Analogia do Aluno

Funciona como uma prova com gabarito; o aluno estuda as questões com respostas para depois fazer a prova sozinho.



Exemplo Prático

Problema: Prever o preço de uma casa.

Dados Históricos:

- 100m², 2q, Centro → R\$ 500k
- 80m², 1q, Periferia → R\$ 300k

Componentes essenciais

- **Conjunto de treino** – usado para aprender
- **Conjunto de teste** – usado para avaliar (nunca visto antes)
- **Algoritmo de aprendizado** – regra de ajuste dos parâmetros
- **Função de previsão** – mapeia entrada → saída

Regressão vs. Classificação

Os dois grandes pilares do aprendizado supervisionado

Regressão

Lida com saídas contínuas e numéricas. O objetivo é prever um valor exato em uma escala infinita.

EXEMPLOS PRÁTICOS

- Qual o preço desta casa?
- Qual será a temperatura amanhã?
- Qual o peso esperado de alguém?

"Qual o peso de uma pessoa com 1,80m?" → **75.5 kg**

Classificação

Lida com saídas discretas ou categorias. O objetivo é atribuir uma etiqueta ou classe aos dados.

EXEMPLOS PRÁTICOS

- Este e-mail é spam ou não?
- Qual a espécie desta flor?
- O tumor é maligno ou benigno?

"Esta pessoa é magra ou pesada?" → **Normal**


Explicando melhor

- **O que é Regressão?**
- **Regressão** é uma técnica de aprendizado de máquina **supervisionada** usada para **prever números** (valores contínuos).
- Se você quer responder "**QUANTO?**" ou "**QUAL O VALOR?**", você usa regressão.

A Régua Mágica

- Imagine que você tem pontos num gráfico:
- **Eixo X (horizontal):** tamanho da casa (m^2)
- **Eixo Y (vertical):** preço da casa (R\$)

- Preço (R\$)



O Modelo Mais Simples: Regressão Linear

- A equação da reta (que você já conhece do ensino médio): $y = ax + b$

- Onde:
- y = o que queremos prever (preço)
- x = a informação que temos (tamanho)
- a = inclinação da reta (quanto o preço aumenta por m^2)
- b = ponto onde a reta corta o eixo Y (preço base)

- **Exemplo numérico**

- Suponha que aprendemos que $a=5$ e $b=50$:
- Preço = $5 \times \text{tamanho} + 50$
- Para uma casa de **70 m^2** :
- Preço = $5 \times 70 + 50 = 350 + 50 = 400$
- R\$ 400 mil
- Para uma casa de **100 m^2** :
- Preço = $5 \times 100 + 50 = 500 + 50 = 550$
- R\$ 550 mil

Como o computador encontra "a" e "b"?

- Ele não chuta! Ele usa os dados de treino e **minimiza o erro**.
- **O que é o erro?**
- Erro= preço real–preço previsto
- O computador tenta encontrar os valores de "a" e "b" que deixam os erros **o menores possíveis**.
- **Analogia do dardo:** Você joga dardos no alvo. Cada dardo é uma previsão. Você quer ajustar sua mira (a e b) para acertar o centro (valor real).

Melhorando: Classificação

- O que é Classificação?
- **Classificação** é uma técnica de aprendizado de máquina **supervisionada** usada para **atribuir um rótulo (categoria)** a um exemplo.
- Se você quer responder "**QUAL CATEGORIA?**" ou "**QUAL TIPO?**", você usa classificação.

Analogia Fundamental – O Fiscal de Show

- Imagine que você é o fiscal na porta de uma boate/festa. Cada pessoa que chega tem características:
 - Idade
 - Tipo de roupa
 - Está com convite?
 - Comportamento
- Você precisa decidir: **entra** ou **não entra**.
- Pessoa chega → Você observa características → Decide classe (ENTRA / NÃO ENTRA)

A Grande Diferença: Regressão vs. Classificação

Pergunta	Tipo	Exemplo de resposta
QUANTO?	Regressão	R\$ 450.000, 28.5°C, 150km/h
QUAL CATEGORIA?	Classificação	"spam", "gato", "doente"

Regra de ouro: Se a resposta é um **rótulo** (categoria, tipo, classe), é classificação!

A Grande Diferença: Regressão vs. Classificação

- **Analogia para regressão vs. classificação**
- **Regressão:** “Qual o peso esperado de uma pessoa com 1,80m?”
- **Classificação:** “Essa pessoa, com 1,80m e 70kg, é magra, normal ou pesada?”

Resumo

- [Diagrama: Dados com rótulos → Algoritmo de treino → Modelo treinado → Nova entrada → Previsão]
- **Como o computador “representa” o aprendizado?**
- Parâmetros internos (números) que capturam o padrão
- Exemplo mais simples: **regressão linear**

Como o Computador Encontra Padrões

A ideia por trás da "Linha de Tendência"

A Linha Mágica

O computador tenta desenhar uma linha que passe o mais perto possível de todos os exemplos que ele já viu.



Importância (Pesos)

O computador decide qual característica é mais importante. Por exemplo: No caso da casa costuma importar mais que a **cor** das paredes.



Analogia da Régua

Imagine que você tem vários pontos espalhados em um papel. Aprender é como colocar uma régua sobre eles de forma que ela represente o "caminho médio" de todos os pontos.



Previsão

Uma vez que a linha está desenhada, se você der um novo tamanho de casa, o computador apenas olha onde esse tamanho "bate" na linha para dizer o preço.

Como o Computador Encontra Padrões

O Problema Central

A Linha Mágica

Um computador não "enxerga" padrões como nós.
Ele só entende **números** e **operações matemáticas**.



Então... como ele descobre que "gatos geralmente têm orelhas pontudas" ou que "casas maiores custam mais caro"?



Analogia: O Aprendiz de Chef

Imagine que você quer ensinar um robô a fazer **o melhor bolo de chocolate**.

O que o robô pode controlar (parâmetros):

Quantidade de açúcar (50g a 200g)
Quantidade de farinha (100g a 300g)
Quantidade de chocolate (30g a 150g)
Temperatura do forno (150°C a 220°C)
Tempo de forno (20min a 50min)

O que o robô quer minimizar (erro):

"As pessoas não gostaram do bolo" → erro alto
"As pessoas amaram o bolo" → erro baixo



O processo de aprendizado:

1. Robô chuta valores aleatórios (ex.: 100g açúcar, 200g farinha, 100°C...)
2. Faz o bolo
3. Recebe feedback (nota de 0 a 10)
4. Ajusta os parâmetros para tentar nota melhor
5. Repete milhares de vezes

No final, o robô "aprendeu" a receita!

O aprendizado de máquina é **exatamente isso**, mas com matemática no lugar de bolos.

Modelos Além da Linearidade

Capturando padrões complexos e não-lineares



Árvores de Decisão

Estruturas de "se-então-senão" aprendidas automaticamente a partir dos dados. São intuitivas e fáceis de interpretar.

Exemplo: "Se tamanho < 60m², então preço baixo; senão, se quartos > 2, então preço médio..."



Não-Linearidade

Muitos problemas reais não podem ser separados por uma linha reta. Exigem fronteiras curvas ou complexas para uma classificação precisa.



Redes Neurais

Inspiradas no cérebro humano, utilizam camadas de neurônios artificiais para aprender funções extremamente complexas. São a base do [Deep Learning](#).



Inductive Bias

Não existe um "melhor modelo para tudo". Cada algoritmo tem uma preferência por certos tipos de padrões. A escolha depende da natureza e complexidade dos seus dados.


Modelos Além da Linearidade

- **ÁRVORE DE DECISÃO**

- **O Problema: Por que "Se-Então-Senão" é Tão Poderoso?**

- Você toma decisões usando "se-então-senão" o tempo todo. Sem perceber.
- **Exemplo banal:** "Se está chovendo, então levo guarda-chuva; senão, não levo."
- Agora imagine que você quer ensinar um computador a **tomar decisões complexas** como:
- Aprovar ou negar um empréstimo?
- Diagnosticar uma doença?
- Recomendar um produto?
- As árvores de decisão fazem exatamente isso: transformam um monte de "se-então-senão" em uma **estrutura de árvore** que o computador pode aprender sozinho a partir de dados.

Anatomia de uma Árvore (Partes com Nomes)



Anatomia da árvore:

- **Analogia da árvore de família:** A raiz é o ancestral comum. Cada nó interno é um parente que faz uma pergunta. As folhas são os descendentes finais (as decisões).

Nome	O que é	No exemplo
Nó raiz	Primeira pergunta	"Tempo ensolarado?"
Nó interno	Perguntas intermediárias	"Umidade?", "Vento forte?"
Ramo	Caminho possível (resposta Sim/Não)	Sim → ramo da esquerda
Nó folha	Decisão final (não pergunta mais)	"Jogar" ou "Não jogar"


Resumindo

- Cada pergunta divide as possibilidades. Quanto mais perguntas, mais específica fica a resposta.
- **Uma árvore de decisão é exatamente isso:** uma sequência otimizada de perguntas que leva a uma conclusão.

Não Linearidade – Explicação Simplificada e Visual

- **O Problema Central: O Mundo Não é uma Reta**
- Imagine que você quer prever a **felicidade** de uma pessoa em função da **quantidade de dinheiro** que ela tem.


Felicidade



- No início, mais dinheiro = mais felicidade (reta crescente).

Mas chega um ponto que **mais dinheiro não traz mais felicidade** (a curva achata).

- Felicidade



- A curva "dobra" – não é mais uma reta!

- Isso é não linearidade: A relação entre as coisas NÃO é uma linha reta. Ela curva, dobra, tem picos, vales, ou padrões irregulares.

Definição Simples

- **Linear:** A saída é proporcional à entrada.
Dobrou a entrada $\rightarrow$ dobrou a saída.
- **Não linear:** A saída NÃO é proporcional à entrada.
Dobrou a entrada $\rightarrow$ a saída pode triplicar, ou ficar igual, ou até diminuir.

Redes Neurais – Explicação Intuitiva e Detalhada

- **O Problema: Como Imitar o Cérebro?**
- O cérebro humano é a máquina de aprendizado mais poderosa que conhecemos.
- ~86 bilhões de neurônios
- Cada neurônio conecta-se a milhares de outros
- Aprende padrões complexos com poucos exemplos
- **A ideia das redes neurais artificiais:** "Vamos copiar (de forma bem simplificada) como o cérebro funciona e ver no que dá."

Analogia Fundamental – O Time de Futebol

- Imagine um time de futebol tentando decidir se um lance foi **impedimento** ou não.
- **Como funciona uma rede neural (analogia):**
- Entrada: Posição dos jogadores, bola, linha de impedimento
- ↓
- [NEURÔNIO 1] "O atacante está à frente da linha?" → Sim/Não
- ↓
- [NEURÔNIO 2] "A bola foi chutada para frente?" → Sim/Não
- ↓
- [NEURÔNIO 3] "Há defensor entre o atacante e o gol?" → Sim/Não
- ↓
- [NEURÔNIO FINAL] "Foi impedimento?" → Decisão final

A mágica:

- Cada neurônio faz uma **pergunta simples**. Juntos, eles resolvem um problema complexo.
- Ninguém programa essas perguntas. O computador **aprende** quais perguntas fazer e como combiná-las.

O Neurônio Artificial (A Unidade Básica)

- **Comparação: Neurônio Biológico vs. Artificial**

Biológico	Artificial	Função
Dendritos	Entradas ($x_1, x_2, \dots, x_n$)	Recebem sinais
Sinapses	Pesos ($w_1, w_2, \dots, w_n$)	Importância de cada entrada
Corpo celular	Soma ponderada ($\sum w_i \times x_i + b$)	Combina os sinais
Axônio	Função de ativação	Dispara ou não o sinal de saída

Exemplo numérico simples:

- Entrada 1: $x_1 = 2$, peso $w_1 = 0.5 \rightarrow 2 \times 0.5 = 1$
- Entrada 2: $x_2 = 3$, peso $w_2 = 0.2 \rightarrow 3 \times 0.2 = 0.6$
- Entrada 3: $x_3 = 1$, peso $w_3 = 0.8 \rightarrow 1 \times 0.8 = 0.8$
- $\text{SOMA} = 1 + 0.6 + 0.8 = 2.4$
- $+ \text{viés } b = 0.5$
- $\text{TOTAL} = 2.9$
- Função ativação (ex.: sigmoid) $\rightarrow \text{saída} \approx 0.95$

Resumindo

- Uma rede neural é como um **cérebro artificial simplificado**. Ela não é programada com regras – ela **aprende com exemplos**, ajustando milhões de "botões" (pesos) até conseguir fazer a tarefa desejada. O deep learning é simplesmente usar **muitas camadas** para aprender padrões em **múltiplos níveis de abstração** – primeiro bordas, depois formas, depois partes, depois objetos completos.

Inductive Bias (Viés Indutivo) – Explicação Simplificada e Detalhada

- **O Problema Fundamental**
- Imagine que você nunca viu um cisne na vida. Alguém mostra UM cisne branco para você.
- O que você conclui?
- **Opção A:** "Todos os cisnes são brancos"
- **Opção B:** "Cisnes podem ser de qualquer cor"
- Você não tem informação suficiente. Qual escolha faz mais sentido?
- **Isso é um viés indutivo:** Uma **suposição** que você faz sobre o mundo para conseguir aprender a partir de exemplos limitados.

Definição Simples

- **Inductive bias (viés indutivo)** = o conjunto de **suposições** que um algoritmo de aprendizado de máquina faz sobre os dados para conseguir aprender.
- Sem essas suposições, o algoritmo não saberia **por onde começar**.
- **Analogia:** É como as "regras do jogo" que você assume antes mesmo de ver as cartas.

Analogia Fundamental – O Detetive e o Suspeito

- Um detetive chega numa cena de crime. Ele tem **poucas evidências**:
- Pegada tamanho 42
- Impressão digital no copo
- Testemunha viu alguém de jaqueta vermelha
- Como ele encontra o culpado?
- **Sem viés indutivo (impossível):**
- Ele teria que considerar **todas as pessoas do mundo** como suspeitas. Impossível resolver.
- **Com viés indutivo (suposições razoáveis):**
- Ele assume:
- "O culpado estava na cena do crime" (elimina 99% das pessoas)
- "Pessoas com jaqueta vermelha são mais prováveis"
- "Pegada tamanho 42 → homem adulto"
- **Essas suposições são o viés indutivo do detetive.** Sem elas, ele não consegue aprender nada com os dados limitados.

Por que Precisamos de Viés Indutivo?

- **O Problema da Indução**

- David Hume (filósofo) observou: Não importa quantos cisnes brancos você veja, **nunca pode provar** que todos os cisnes são brancos.
- Em machine learning:
- Você tem **exemplos limitados** (treino)
- Precisa **generalizar** para exemplos nunca vistos (teste)
- Sem suposições, QUALQUER padrão é possível

Exemplo numérico:

- Dados: $(x=1, y=2)$, $(x=2, y=4)$, $(x=3, y=6)$
- Qual é o padrão?

Possibilidade	Fórmula	Previsão para $x=4$
Linear	$y = 2x$	8
Quadrático	$y = x^2 + 1$	17
Senoidal	$y = 2x + \sin(\pi x)$	8
Aleatório	$y = 2x + (x-1)(x-2)(x-3) \times 1000$	6008

Todas as opções se encaixam nos dados de treino!

Sem viés indutivo, você não consegue escolher entre infinitas possibilidades.

Como Escolher o Viés Certo?

- Regras práticas:

Se você tem...	Use modelo com viés...	Exemplo
Poucos dados	Forte (alto viés)	Regressão linear, Naive Bayes
Muitos dados	Fraco (baixo viés)	Rede neural, Random Forest
Relações simples	Linear	Regressão, SVM linear
Relações complexas	Não linear	Rede neural, árvore
Necessidade de explicar	Interpretável	Árvore, regressão linear
Dados não estruturados (imagem, áudio)	Hierárquico	Rede neural (CNN)

Você escolhe a ferramenta certa para o trabalho. Não usa um martelo para apertar um parafuso.

Exercícios

- 1. Defina, com suas palavras, aprendizado de máquina supervisionado.
- 2. Explique a diferença entre:
 - a) Conjunto de treino e conjunto de teste.
 - b) Feature (atributo) e rótulo (label).
 - c) Modelo e algoritmo de aprendizado.
- 3. Uma imobiliária quer prever o preço de venda de imóveis. Eles coletaram:
 - Tamanho (m²)
 - Número de quartos
 - Idade da casa
 - Localização (Centro, Zona Norte, Zona Sul, Zona Leste, Zona Oeste)
 - Quais são as **features**? Qual é o **rótulo**?

Exercicios

- 4. Explique a diferença entre:
 - a) Conjunto de treino e conjunto de teste.
 - b) Feature (atributo) e rótulo (label).
 - c) Modelo e algoritmo de aprendizado.
- 5. Por que não podemos usar os mesmos dados para treinar e testar um modelo?
O que aconteceria se fizéssemos isso?

O Processo de Aprendizado e Otimização

Ajustando os "botões" para minimizar o erro

Função de Custo (Perda)

Mede a distância entre a previsão do modelo e a verdade real. O objetivo do aprendizado é **minimizar** esse valor.

$$MSE = (1/n) * \sum (y - \hat{y})^2$$

Analogia do Alvo

Os parâmetros (w, b) são os botões de mira. A função de custo é a distância do tiro ao centro. Ajustamos os botões até acertar o alvo.

Gradiente Descendente

Algoritmo que calcula a direção da descida mais íngreme para reduzir o erro passo a passo.

Analogia da Neblina

Imagine estar no topo de uma montanha com neblina. Você sente o chão com os pés para saber para onde é a descida. Dá um passo nessa direção e repete até chegar ao vale (o erro mínimo).

Função de Custo (Perda) – Explicação Detalhada e Intuitiva


- **O Problema Central**

- Imagine que você é um **professor** e quer ensinar um aluno a acertar o alvo.
- O aluno chuta → você diz o quanto errou → ele ajusta a mira → repete.
- **A função de custo é a "nota" que você dá para o erro do aluno.** Quanto menor a nota (custo), melhor o aluno (modelo).
- Sem uma função de custo, o algoritmo não teria como saber se está melhorando ou piorando.

Definição Simples

- **Definição Simples**
- **Função de custo (ou função de perda, loss function)** = uma fórmula matemática que **quantifica o erro** de um modelo.
- Ela responde à pergunta:
- **"O quão ruim é a previsão do meu modelo em relação ao valor real?"**
- Quanto menor o valor da função de custo, melhor o modelo.

Analogia Fundamental – O Jogo de Dardos



Gradiente descendente

- **O Problema Central**

- Você tem uma **função de custo** (aquele "erro" que queremos minimizar). O problema é:
- **Como encontrar os parâmetros (w , b) que deixam essa função NO SEU PONTO MAIS BAIXO?**
- **O gradiente descendente é o algoritmo que nos permite "descer a montanha" até o ponto mais baixo.**

Generalização: O Desafio do Overfitting

O equilíbrio entre decorar e aprender

Overfitting (Sobreajuste)

O modelo "decora" o ruído dos dados de treino. Resultado: erro baixo no treino, mas alto em dados novos (teste).

Underfitting (Subajuste)

O modelo é simples demais para capturar o padrão básico. Resultado: erro alto tanto no treino quanto no teste.



Analogia do Aluno

É o aluno que decora as questões exatas do simulado, mas não entende a lógica. Ele vai bem no simulado, mas falha na prova real com questões novas.



Como Evitar?

- ✓ Coletar mais dados de treino
- ✓ Simplificar a complexidade do modelo
- ✓ Regularização (penalizar pesos grandes)
- ✓ Parada antecipada (Early Stopping)

Como Sabemos se o Modelo é Bom?

Medindo a "inteligência" do computador

✓ Taxa de Acerto (Acurácia)

É a porcentagem de vezes que o computador acertou a resposta. Se ele acertou 90 de 100 fotos, sua acurácia é de 90%.

Importante: Nem todo erro é igual. Errar um diagnóstico médico é muito mais grave do que errar uma recomendação de filme.



A Prova Final

Sempre guardamos uma parte dos dados (o "Teste") que o computador nunca viu. Se ele for bem nessa prova, ele realmente aprendeu o conceito.



Tipos de Erros

Falso Positivo

Dizer que é algo quando não é.

Falso Negativo

Dizer que não é quando na verdade é.

Ciclo de Vida e Ética em IA

Do pré-processamento à responsabilidade social



Fluxo de Trabalho Típico

- 1 Coleta e Limpeza de Dados
- 2 Divisão Treino / Teste
- 3 Escolha e Treinamento do Modelo
- 4 Avaliação e Ajuste de Hiperparâmetros
- 5 Implantação e Monitoramento



Cuidados Éticos

Modelos podem perpetuar preconceitos se os dados históricos forem enviesados. A IA deve ser justa, transparente e explicável.

Exemplo: Sistemas de recrutamento que penalizavam mulheres devido a padrões históricos de contratação enviesados.

Dúvidas? Vamos aos exercícios!