
Aprendizagem de Máquina - Parte 2

Não Supervisionada e Aprendizagem por Reforço

Revisão Rápida – Os Três Paradigmas

Supervisionada:
Aprende com exemplos rotulados (entrada → saída conhecida).


Não Supervisionada:
Descobre estruturas ocultas sem rótulos.

Por Reforço: Aprende por tentativa e erro, maximizando recompensas.

O que é Aprendizagem Não Supervisionada?

Diferente da aprendizagem supervisionada, aqui o algoritmo recebe apenas entradas, sem rótulos ou respostas conhecidas. O computador deve "descobrir" sozinho a estrutura dos dados.

- 🔍 Objetivo: encontrar estruturas ocultas, padrões ou agrupamentos naturais nos dados.
- 📦 Analogia: Organizar uma caixa de objetos nunca vistos por semelhança, sem saber as categorias.
- 📊 Essencial para explorar dados onde rótulos são caros ou difíceis de obter no mundo real.



Por que usar Aprendizagem Não Supervisionada?

Dados do mundo real raramente vêm com rótulos.

Rotular manualmente é caro, lento ou inviável.

Útil para:

Explorar dados novos

Reduzir dimensionalidade

Detectar anomalias

Segmentar clientes

Principais Tarefas

A aprendizagem não supervisionada abrange diversas técnicas para extrair valor e conhecimento de dados brutos e não estruturados.



Clusterização

Agrupar elementos semelhantes e separar os dissemelhantes (ex: segmentação de clientes).



Associação

Descobrir regras que descrevem relações entre itens (ex: análise de cesta de compras).



Redução de Dimensionalidade


Simplificar dados complexos mantendo as informações essenciais para visualização.



Detecção de Anomalias

Identificar pontos que fogem drasticamente do padrão esperado (ex: detecção de fraudes).

Clustering



Clusterização – Agrupando Dados Semelhantes

Objetivo: formar grupos onde elementos dentro do mesmo grupo são mais parecidos entre si do que com os de outros grupos.

Exemplo: segmentação de clientes por comportamento de compra.

Algoritmo clássico: K-Means.



Associação – Regras do Tipo "Se-Então"



Descobrir itens que aparecem juntos com frequência.



Exemplo clássico: quem compra pão também compra manteiga.



Método comum: Algoritmo **Apriori**.



Aplicações: recomendação de produtos, análise de cestas de compras.

Redução de Dimensionalidade – Simplificando Dados

Dados com muitas variáveis (ex: 100 características) são difíceis de visualizar e processar.

Técnicas como PCA (Análise de Componentes Principais) reduzem o número de dimensões mantendo a informação mais relevante.

Benefícios: menos custo computacional, menos overfitting, visualização possível.



Detecção de Anomalias – Encontrando o Diferente



Identificar pontos que fogem drasticamente do padrão esperado.



Exemplos: fraudes em cartões, falhas em máquinas, intrusões em redes.



Técnicas: Isolation Forest, One-Class SVM, autoencoders.

Algoritmo clássico: K-Means


O que o K-Means faz?

Ele agrupa coisas parecidas automaticamente.

Imagine que você tem várias bolinhas coloridas espalhadas em uma mesa, mas você não sabe as cores (só vê a posição delas). O K-Means vai juntar as bolinhas que estão perto umas das outras em grupos.

Algoritmo K-Means

- Passo 1** Definição de **K** e escolha aleatória dos centroides iniciais no espaço de dados.
- Passo 2** Cada ponto de dado é atribuído ao centroide mais próximo (distância euclidiana).
- Passo 3** Recálculo da posição dos centroides como a média aritmética de todos os pontos do grupo.
- Passo 4** Repetição dos passos 2 e 3 até que as atribuições não mudem mais (convergência).
- Cotovelo** O **Método do Cotovelo** ajuda a encontrar o K ideal observando a variância intra-cluster.



Redução de Dimensionalidade e PCA

O PCA (Principal Component Analysis) simplifica dados complexos, reduzindo o número de variáveis enquanto preserva a informação mais importante e a variância dos dados (A **variância** é uma medida estatística que indica o quão dispersos os dados estão em relação à média.).

🔪 Maldição da Dimensionalidade

Combate o excesso de variáveis que causa alto custo computacional e dados esparsos.

📈 Variância Máxima


Encontra as direções (componentes principais) que melhor explicam a dispersão dos dados.

👁 Visualização de Dados

Permite projetar dados de alta dimensão em espaços 2D ou 3D compreensíveis.

📷 Analogia da Fotografia

Como escolher o melhor ângulo para capturar a essência de um objeto 3D em uma foto 2D.



Maldição da Dimensionalidade

À medida que o número de variáveis aumenta, os dados ficam esparsos (pontos muito distantes uns dos outros).


Isso dificulta qualquer aprendizado estatístico.

PCA ajuda a combater esse problema.

O que é Aprendizagem por Reforço?

É um paradigma de Machine Learning onde um agente aprende a tomar decisões sequenciais interagindo com um ambiente para atingir um objetivo.

- 🔧 Aprendizado por tentativa e erro: o agente testa ações e observa os resultados.
- 🏆 Feedback via recompensas: sinais numéricos que reforçam comportamentos desejados.
- 📈 Objetivo: maximizar a recompensa acumulada ao longo de toda a interação.



Elementos Fundamentais

O aprendizado por reforço baseia-se em um ciclo contínuo de interação entre o agente e o seu meio ambiente.



Agente

A entidade que toma decisões e aprende com as consequências de suas ações.



Ambiente

O mundo externo com o qual o agente interage e recebe feedback.




Estado e Ação

A situação atual do agente e a decisão tomada para mudar essa situação.



Recompensa

O sinal numérico que indica o sucesso ou falha da ação tomada pelo agente.



Ciclo Agente-Ambiente

Agente observa o estado.

Escolhe uma ação.

Ambiente muda de estado e retorna uma recompensa.

Agente atualiza seu conhecimento.

Repete.

Exploração vs. Exploração

O dilema central da aprendizagem por reforço: como equilibrar a busca por novas estratégias com o uso do que já foi aprendido.



Exploração

Tentar ações novas e desconhecidas para descobrir recompensas potencialmente maiores no ambiente.




Exploração

Utilizar o conhecimento já adquirido para obter a melhor recompensa imediata conhecida.



O Equilíbrio

Essencial para evitar soluções subótimas e garantir que o agente maximize ganhos a longo prazo.



Exemplo Clássico – O Restaurante

Você vai sempre ao restaurante que já conhece (exploração) ou experimenta um novo (exploração)?


O novo pode ser melhor... ou pior.

Equilíbrio é a chave para aprendizado eficiente.



Q-Learning e Deep Q-Learning

Q-Learning e Deep Q-Learning



Técnicas avançadas para mapear a qualidade das ações em estados complexos, permitindo que a IA aprenda estratégias ótimas.



Tabela Q

Registro da "qualidade" de cada ação possível em cada estado do ambiente.



Equação de Bellman

O fundamento matemático para atualizar valores com base em recompensas futuras.



Deep Q-Learning (DQN)

Uso de redes neurais para lidar com espaços de estados vastos e complexos.

"A Equação de Bellman permite que o agente aprenda não apenas com a recompensa imediata, mas com o valor futuro esperado de suas ações."

Q-Learning – Aprendendo a Qualidade das Ações

- **Tabela Q:** matriz onde cada célula $Q[\text{estado}, \text{ação}]$ representa a "qualidade" esperada daquela ação naquele estado.

- Atualização pela **Equação de Bellman:**

$$Q(s, a)$$

$$\leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$


- α : taxa de aprendizado, γ : fator de desconto para recompensas futuras.

Aplicações Práticas e Desafios

A combinação de descoberta de padrões e tomada de decisão autônoma está moldando o futuro da inteligência artificial em diversos setores.

-  Sucessos em jogos complexos como AlphaGo e Atari
-  Avanços em carros autônomos e sistemas de navegação
-  Otimização de robótica industrial e data centers

"O desafio não é apenas aprender, mas aprender a agir de forma inteligente em mundos incertos."



Desafios da Aprendizagem por Reforço

Necessidade de muitas interações (ineficiente no mundo real).

Dificuldade em definir recompensas adequadas.

Risco de comportamento inseguro durante exploração.

Instabilidade no treinamento com redes neurais.

Paradigma	Entrada	Saída	Feedback	Exemplo
Supervisionado	Dados + rótulos	Previsão	Correção de erro	Classificação
Não supervisionado	Dados apenas	Padrões	Nenhum	Segmentação
Por reforço	Estado + recompensa	Ação	Recompensa	Controle

Comparação Rápida dos Paradigmas

Resumo Final

Não supervisionada: descobre estruturas sem rótulos (clusterização, PCA, associação).

Por reforço: aprende por tentativa e erro maximizando recompensas futuras.

K-Means e PCA são ferramentas fundamentais.

Q-Learning e DQN resolvem problemas sequenciais complexos.

Conclusão e Próximos Passos

O futuro da IA combina padrões ocultos com decisões autônomas.

Áreas promissoras: IA explicável, aprendizado por reforço profundo, autoML.

Desafio final: não apenas aprender, mas aprender a agir inteligentemente em mundos incertos.

Exercícios

1. Explique, com suas palavras, a diferença fundamental entre aprendizado supervisionado e não supervisionado. Dê um exemplo real de cada um.
2. Descreva o funcionamento do algoritmo K-Means passo a passo. Qual é o papel do método do cotovelo e como ele auxilia na escolha do número de clusters?
3. O que é a "maldição da dimensionalidade" e como técnicas como o PCA ajudam a mitigar esse problema? Use uma analogia para ilustrar.
4. Compare os objetivos da clusterização, da redução de dimensionalidade e da detecção de anomalias no contexto da aprendizagem não supervisionada.
5. Explique o dilema "exploração vs. exploração" na aprendizagem por reforço. Por que esse equilíbrio é essencial para o sucesso do agente?
6. Descreva os cinco elementos fundamentais de um sistema de aprendizagem por reforço: agente, ambiente, estado, ação e recompensa. Dê um exemplo concreto (ex: robô aspirador).
7. O que é a Equação de Bellman e qual sua importância no Q-Learning? Explique como ela permite que o agente aprenda recompensas futuras, não apenas imediatas.
8. Diferencie Q-Learning tradicional de Deep Q-Learning (DQN). Em que situações o DQN se torna necessário?
9. Cite e explique pelo menos três aplicações reais da aprendizagem por reforço. Para cada uma, identifique qual seria a recompensa e qual o desafio principal.
10. Imagine que você recebe um grande conjunto de dados de compras de um supermercado, sem nenhum rótulo. Proponha duas abordagens diferentes de aprendizagem não supervisionada para extrair valor desses dados. Justifique.